

UNIVERSIDADE FEDERAL FLUMINENSE
INSTITUTO DE COMPUTAÇÃO
DEPARTAMENTO DE CIÊNCIA DA COMPUTAÇÃO

Pedro Henrique Bose Ximenes Pedrosa

Análise da Predição de Chuvas através de Modelos de Aprendizado Profundo

Trabalho de Conclusão de Curso submetido ao Departamento de Ciência da Computação da Universidade Federal Fluminense como requisito parcial para a obtenção do título de Bacharel em Ciência da Computação.

Niterói
2025

Pedro Henrique Bose Ximenes Pedrosa

Análise da Predição de Chuvas através de Modelos de Aprendizado Profundo

Trabalho de Conclusão de Curso submetido ao Departamento de Ciência da Computação da Universidade Federal Fluminense como requisito parcial para a obtenção do título de Bacharel em Ciência da Computação.

Aprovado em 15 de dezembro de 2025:

Prof. Leandro Santiago de Araújo
Orientador - UFF

Dsc. Gyslla Santos de Vasconcelos
UFF

Prof. Taiane Coelho Ramos
UFF

Msc. Alana de Lima Pontes Gadelha
Marinha do Brasil

Niterói
2025

Ficha catalográfica automática - SDC/BEE
Gerada com informações fornecidas pelo autor

P372a Pedrosa, Pedro Henrique Bose Ximenes
 Análise da Predição de Chuvas através de Modelos de
 Aprendizado Profundo / Pedro Henrique Bose Ximenes Pedrosa. -
 2025.
 35 f.: il.

 Orientador: Leandro Santiago De Araújo.
 Trabalho de Conclusão de Curso (graduação)-Universidade
 Federal Fluminense, Instituto de Computação, Niterói, 2025.

 1. Previsão de Chuva. 2. Aprendizado de Máquina. 3.
 Análise de Série Temporal. 4. Rio de Janeiro. 5. Produção
 intelectual. I. Santiago De Araújo, Leandro, orientador. II.
 Universidade Federal Fluminense. Instituto de Computação.
 III. Título.

CDD - XXX

Análise da Predição de Chuvas através de Modelos de Aprendizado Profundo

Rainfall Prediction Analysis Using Deep Learning Models

Pedro Henrique Bose Ximenes Pedrosa ¹

Leandro Santiago de Araújo²

Resumo

Eventos climáticos extremos, como chuvas torrenciais, têm ocorrido com maior frequência e intensidade, causando graves impactos socioeconômicos e perdas humanas, especialmente em regiões vulneráveis como a cidade do Rio de Janeiro. Diante das limitações dos modelos físicos tradicionais de previsão numérica, a Inteligência Artificial surge como uma alternativa promissora para lidar com a complexidade e a não linearidade dos dados meteorológicos. Este trabalho avalia o desempenho dos modelos *Random Forest*, LSTM, BiLSTM e ARIMA na previsão de precipitação mensal em duas estações da cidade do Rio de Janeiro, obtidas de diferentes bases de dados, utilizando dados históricos de chuva e variáveis climáticas adicionais, após pré-processamento com normalização. Foram realizados três experimentos, variando configurações e atributos de entrada, e também avaliadas métricas de sustentabilidade computacional, como consumo de energia e pegada de carbono. Os resultados mostram que a previsão de chuva permanece uma tarefa desafiadora, mas *Random Forest*, LSTM e BiLSTM revelaram-se as abordagens mais promissoras. No entanto, os modelos de aprendizado profundo (LSTM e BiLSTM) geraram séries de previsão mais realistas, com picos de precipitação mais semelhantes aos dados observados, enquanto o ARIMA produziu curvas mais lineares e suavizadas, com menor capacidade de representar os extremos. Observou-se ainda que dados sem normalização preservam melhor os picos de chuva intensa. Em termos de sustentabilidade, todos os modelos apresentaram baixo custo energético, com maior tempo de treinamento associado a arquiteturas mais complexas. O estudo contribui para uma análise de predição de chuva com diversos algoritmos na cidade do Rio de Janeiro e fomenta a discussão sobre a eficiência energética na IA aplicada à meteorologia.

Palavras-chaves: Previsão de Chuva; Aprendizado de Máquina; Previsão de Série Temporal, Análise de Série Temporal; LSTM; BiLSTM; Random Forest; ARIMA; Previsão Rio de Janeiro; Sustentabilidade Computacional

¹ Graduando do Curso de Ciência da Computação - UFF, pedrobose@id.uff.br

² Orientador - Instituto de Computação - UFF, leandro@ic.uff.br.

Abstract

Rainfall extremes, such as torrential rain, have become more frequent and intense, causing severe socioeconomic impacts and human losses, especially in vulnerable regions like the city of Rio de Janeiro. Given the limitations of traditional numerical weather prediction models, Artificial Intelligence emerges as a promising alternative to handle the complexity and non-linearity of meteorological data. This work evaluates the performance of Random Forest, LSTM, BiLSTM and ARIMA models for monthly rainfall prediction at two stations in Rio de Janeiro, using data from different databases, historical rainfall records and additional climate variables, after data preprocessing with normalization. Three experiments were conducted, varying model configurations and input features, and computational sustainability metrics such as energy consumption and carbon footprint were also assessed. The results show that rainfall forecasting remains a challenging task, although precipitation forecasting proves to be a complex task, the *Random Forest*, LSTM, and BiLSTM models showed promising results. However, the deep learning models (LSTM and BiLSTM) produced more realistic prediction series, with rainfall peaks closer to the observed data, while ARIMA generated more linear and smoothed curves, with lower capability to represent extremes. It was also observed that non-normalized data preserve intense rainfall peaks more effectively. In terms of sustainability, all models showed low energy cost, with longer training time associated with more complex architectures. This study contributes to rainfall prediction analysis using multiple algorithms in Rio de Janeiro and promotes the discussion on energy efficiency in AI applied to meteorology.

Keywords: Rainfall prediction; Deep learning; Time Series Forecasting, Time Series Analysis, LSTM; BiLSTM; Random Forest; ARIMA; Rio de Janeiro Forecasting; Green AI.

Aprovado em: 15/12/2025. **Versão Final em:** 19/12/2025

1. INTRODUÇÃO

Eventos climáticos extremos ocorrem com cada vez mais frequência, causando perdas materiais, humanas, animais, danos ao meio ambiente e risco à saúde, como por exemplo: chuvas torrenciais, definidas pelo grande volume de precipitação em pouco período de tempo. Seus impactos são severos na sociedade, no âmbito social e econômico. Em 2011, o estado do Rio de Janeiro foi afetado por várias tempestades, que em poucos dias alagou cidades inteiras, principalmente, na região serrana, causando deslizamento de terra. Como consequência negativa mais de 300 mil pessoas foram afetadas e 900 perderam suas vidas (BARCELLOS; CATALDI, 2020). Prever e mitigar desastres naturais é urgente, especialmente em regiões com poucos

recursos para enfrentar esses eventos. Estudos recentes indicam que as mudanças climáticas têm aumentado tanto a frequência quanto a intensidade desses eventos, com efeitos mais acentuados em áreas tropicais como o Brasil (IPCC, 2023).

A chuva é um fenômeno meteorológico complexo porque envolve muitas variáveis e tem um comportamento não linear. Mesmo sob condições parecidas, a probabilidade de chover pode mudar de um momento para outro (BOVE; PELINO; De Leonibus, 2006). A previsão de chuva tem sido tradicionalmente conduzida com base em modelos físicos conhecidos como Previsão Numérica do Tempo. Esses modelos resolvem sistemas complexos de equações diferenciais que descrevem o movimento atmosférico, utilizando condições iniciais e de contorno para projetar o estado futuro da atmosfera (HUANG; ISAAC; SHENG, 2012). Embora sejam amplamente utilizados em diferentes partes do mundo, esses sistemas apresentam limitações. Sua precisão depende fortemente da qualidade das condições iniciais e de contorno, e seu desempenho tende a ser insatisfatório em horizontes muito curtos (MA; ZHANG; LIU, 2023). Ademais, modelos de alta resolução, embora mais precisos, exigem grande capacidade computacional, o que limita sua aplicação em tempo real e em larga escala.

Os eventos de precipitação são séries temporais, isto é, uma sequência de dados coletados em intervalos regulares ao longo do tempo, organizada de forma cronológica. As observações das séries temporais não são independente, então, um dado do passado influencia na previsão do futuro. Nesse contexto, a área de Inteligência Artificial tem sido usada como um caminho para contribuir na predição de chuva. Os algoritmos de aprendizado de máquina processam um conjunto de dados históricos e analisam tendências e sazonalidades, capturando padrões complexos dos dados para prever informações futuras, sem a necessidade de representar explicitamente os processos físicos.

A cidade do Rio de Janeiro é, historicamente, vulnerável a eventos de chuva torrencias, com fortes impactos na infraestrutura e na segurança da população. Em (FONSECA *et al.*, 2022), os autores aplicaram a Teoria do Valor Extremo a 25 anos de dados pluviométricos para descrever o comportamento estatístico dessas ocorrências. Já em (SILVA *et al.*, 2025), os autores apresentaram uma análise de predição de chuva com uso de aprendizado de máquina por região brasileira, de forma generalizada. Ambos os estudos reforçam a adoção de abordagens mais precisas e específicas para o município.

Não foram encontrados trabalhos anteriores que aplicassem modelos de aprendizado profundo baseados em LSTM ou BiLSTM para previsão de chuva na cidade do Rio de Janeiro. Ademais, apenas uma das pesquisas revisadas até o momento apresentou métricas de sustentabilidade computacional, como consumo energético, emissões de carbono (CO₂).

Este trabalho propõe analisar dados de estações meteorológicas para prever

a precipitação no Rio de Janeiro em um período de um mês, com diferentes bases de dados. O objetivo principal é avaliar o desempenho dos modelos *Random Forest*, LSTM, BiLSTM e ARIMA na previsão de chuvas, analisando os resultados de cada algoritmo. São avaliados dados históricos de chuva e algumas variáveis climáticas em duas estações do Rio de Janeiro, e os modelos são comparados quanto aos erros das previsões. Foram realizados experimentos com configurações diferentes, em que será aprofundado no decorrer do texto.

As contribuições dessa pesquisa estão enumeradas a seguir:

1. Desenvolvimento de técnicas de pré-processamento e extração adequada de dados meteorológicos da cidade do Rio de Janeiro;
2. Implementação de 3 modelos de aprendizado de máquina para a previsão de chuva;
3. Investigação de novas *features* que possam contribuir para melhorar a previsão de chuva;
4. Avaliação dos modelos desenvolvidos em termos de medidas de qualidade (erro médio, erro absoluto, etc), tempo de processamento e eficiência energética.

A organização do texto está estruturada da seguinte forma: a Seção 2 introduz a base teórica dessa pesquisa, bem como os métodos de aprendizado de máquina empregados; a Seção 3 apresenta estudos envolvendo predição de chuva; a Seção 4 demonstra a metodologia desenvolvida neste trabalho, abordando as bases de dados e o processamento de informações; a Seção 5 discute os resultados qualitativos e eficiência energética obtidos dos experimentos; por fim, as conclusões e trabalhos futuros são expostos na Seção 6.

2. REFERENCIAL TEÓRICO

Esta seção aborda o referencial teórico necessário para sustentar os métodos e experimentos desenvolvidos nesta pesquisa. Primeiro, discutimos os principais tipos de eventos climáticos extremos e seus impactos socioambientais (Seção 2.1). Após isso, revisamos os fundamentos de aprendizado de máquina aplicados à meteorologia, com ênfase nas arquiteturas de redes neurais recorrentes e suas extensões modernas (Seção 2.2). Essa base estabelece o contexto científico e tecnológico que embasa a metodologia experimental apresentada nas próximas seções.

2.1. EVENTOS CLIMÁTICOS EXTREMOS

Eventos climáticos extremos são acontecimentos de baixa frequência, porém, de grande impacto na sociedade e no ambiente. Esses eventos, em geral, são: chuvas

torrenciais, ondas de calor severas e tempestades violentas. Realizar estudos sobre essas ocorrências têm extrema importância, visto que, tais eventos causam grande devastação, incluindo deslizamentos de terra, destruição de infraestruturas, enchentes, perda de vidas humanas e consequências econômicas severas. Além disso, é importante pesquisar, também, devido ao aumento de ocorrências e de intensidade desses eventos em um contexto de mudança climática. Resultado de pesquisas indicam que precipitações extremas continuaram aumentando, paralelamente, com o crescimento das temperaturas globais (IPCC, 2023).

O entendimento detalhado e a previsão precisa são importantes para mitigar os danos causados por esses eventos e para preparar ações eficazes nos casos. No Brasil, a Agência Nacional de Águas e Saneamento Básico (ANA) reportou em 2017, que aproximadamente três milhões de pessoas foram impactadas por inundações ou enchentes naquele ano (COSTA *et al.*, 2025). As cidades metropolitanas localizadas na região sudoeste do país são afetadas não apenas pelas enchentes, mas também pelos deslizamentos de terra, que se intensificam com o aumento da frequência desses eventos.

Relatórios do Painel Intergovernamental sobre Mudanças Climáticas (IPCC) detalha que as ações humanas interferem, diretamente, na mudança climática ao longo dos séculos. O aquecimento global vem aumentando a cada ano, principalmente devido a interferência humana, contribuindo com emissões de gases poluentes na atmosfera e aumento da urbanização. A consequência disso implica no aumento da intensidade e frequência das chuvas extremas desde 1950 na maioria das áreas do mundo (IPCC, 2023).

A compreensão e a previsão de chuvas extremas são fundamentais para mitigar seus efeitos adversos, sobretudo em áreas urbanas suscetíveis como o Rio de Janeiro. O sistema Alerta Rio classifica como chuva extrema a precipitação igual ou superior a 50 mm em uma hora, indicando alto risco de alagamentos, deslizamentos e sérios transtornos urbanos (Sistema Alerta Rio, 2025). A previsão desses fenômenos, contudo, enfrenta grandes desafios devido à complexidade topográfica da cidade, à elevada densidade urbana e à forte variabilidade espacial e temporal das chuvas. Nesse cenário, destaca-se a necessidade do uso de ferramentas computacionais avançadas e métodos baseados em aprendizado de máquina, capazes de integrar dados históricos a modelos que representam, com maior precisão e eficiência, a dinâmica da atmosfera associada a eventos extremos.

2.2. REDES NEURAIIS RECORRENTES

2.2.1. Redes Neurais

As redes neurais artificiais (RNAs) são amplamente utilizadas para abordar problemas complexos, principalmente quando há incerteza no comportamento das

variáveis envolvidas. Uma das suas principais vantagens é a capacidade de aprenderizado a partir de exemplos e a habilidade de generalizar esse conhecimento para novas situações. Por serem capazes de modelar relações não-lineares, essas redes tornam-se ferramentas eficientes em diferentes campos como, por exemplo, em processos de modelagem, análise de séries temporais, reconhecimento de padrões, processamento de sinais e controle de processos (FLECK *et al.*, 2016).

Com isso, as RNAs são um sistema complexo com camadas de neurônios artificiais, que estão conectadas através de pesos sinápticos. Pode existir um ou mais neurônios de entrada, onde irão receber os dados do contexto do problema, um ou mais neurônios na camada de saída, onde é disponibilizado uma possível solução do problema, e a camada intermediária (camada oculta), onde ficam os neurônios que realizam o processamento.

Cada neurônio artificial calcula uma saída, por meio de operações matemáticas com o pesos sinápticos e uma função de ativação (AF). Além disso, nesses cálculos, existe uma adição com um peso, que é um valor constante e diferente de zero ao neurônio em questão, conhecido como *bias*. Para utilizar uma RNA é necessário a avaliação dos valores dos pesos sinápticos e do *bias*. Os parâmetros são inicializados vazios e a estimativa é calculada iterativamente, no processo conhecido como treinamento (LEANDRO; SANTOS; PEREIRA, 2020).

Em cada passo da etapa de aprendizagem, a rede recebe dados de entrada e percorre camada por camada até gerar uma resposta, em um processo conhecido como propagação. A partir daí, o erro calculado na saída é enviado de volta pela rede e usado para ajustar os pesos sinápticos, na busca de melhorar o desempenho em novas previsões, conhecido como retropropagação (*backpropagation*).

Existem benefícios e desvantagens no uso de Redes Neurais Artificiais. Suas principais vantagens estão relacionadas a sua capacidade de aprender e se adaptar, ajustando os próprios parâmetros conforme novos dados ou mudanças no ambiente, e sua habilidade de modelar relações não-lineares entre variáveis, o que torna eficaz, especialmente, na resolução de problemas complexos. Entretanto, as desvantagens cruciais estão ligadas a respostas contrárias às teorias previstas, onde apenas um especialista com conhecimento do contexto e bom senso poderá solucionar, e em alguns casos não é possível saber o motivo que levou a rede a uma determinada conclusão. Na maioria dos cenários, o correto aprendizado da rede exige um grande volume de dados históricos, o que pode demandar tempo e recursos.

2.2.2. Redes Neurais Recorrentes

As Redes Neurais Recorrentes (RNN) são um tipo de arquitetura de Rede Neural Artificial (RNA) adequado à problemas com contexto sequenciais, isto é, dados que são apresentados de acordo com uma sequência seguindo uma ordem.

A principal diferença se baseia no fato de manter um estado interno com os dados anteriores. Conforme mostrado na Figura 1, uma rede com uma camada oculta com n estados permite que as informações passadas contribuam no processamento atual (MIENYE; SWART; OBAIDO, 2024). Em outras palavras, os dados produzidos na camada de saída são retro-alimentados nas primeiras camadas da rede. Desta forma, o estado da camada oculta é atualizado por uma função de ativação sobre a combinação dos valores de entrada e duas matrizes de pesos: a primeira associada pela conexão da entrada à camada oculta e a segunda associada as conexões recorrentes internas (estados anteriores), acrescidos do termo *bias*.




Figura 1 – Exemplo de arquitetura de uma rede RNN. Fonte: (MIENYE; SWART; OBAIDO, 2024).

A escolha da função de ativação aplica um papel importante no comportamento do modelo, pois permite a introdução de não linearidade, para aprender e prever padrões complexos de dados. As funções mais comumente utilizadas são: a tangente hiperbólica ($\tanh$), o sigmóide (σ) e a unidade linear retificada (relu), que são representadas da seguinte forma:

$$\text{Tangente hiperbólica: } \tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (1)$$

$$\text{ReLU: } \text{ReLU}(x) = \max(0, x) \quad (2)$$

$$\text{Sigmóide: } \sigma(x) = \frac{1}{1 + e^{-x}} \quad (3)$$

A tangente hiperbólica (1) atribui os valores de entrada em um intervalo de $[-1, 1]$, o que torna os resultados em torno do zero. A unidade linear retificada (2) retorna o valor real de saída se o de entrada for maior que zero ou retorna zero,

isto é, o intervalo varia de zero até infinito. A sigmóide retorna uma solução em um intervalo de $[0,1]$. Essa escolha depende diretamente do contexto em que a rede é aplicada, uma vez que há diferentes problemas e desafios referentes às RNNs, os quais serão abordados a seguir.

Os desafios principais enfrentado pelas RNN são os problemas de dissipação e de explosão de gradiente. Na retropropagação ao longo do tempo, os gradientes podem tender a diminuir ou crescer exponencialmente, o que dificulta a rede de encontrar dependências longas ou causa instabilidade no treinamento da rede. Para ultrapassar essas barreiras foram desenvolvidos variações das RNN, como as redes: *Long Short-Term Memory* (LSTM) e *Bidirectional Long Short-Term Memory* (BiLSTM), que usam um princípio de portões de esquecimento e entrada, buscando a conservação do gradiente ao longo do tempo.

2.2.3. LSTM

A LSTM (*Long Short-Term Memory*) é uma evolução das RNN tradicionais com o objetivo de superar o problema do sumiço do gradiente (*vanish gradient*). A principal inovação nessa arquitetura foi a implementação de mecanismos de portas, buscando manter o controle do fluxo em toda a rede neural. Cada célula interna contém três portas principais, sendo elas: porta de entrada, esquecimento e de saída, o que torna eficaz em tarefas de dependências longas (MIENYE; SWART; OBAIDO, 2024).

A Figura 2 ilustra um exemplo da arquitetura interna de uma célula LSTM, que é construída através da representação de portas com diferentes papéis durante o processamento. A porta de entrada controla o quanto da nova entrada é escrito no estado da célula. O portão de esquecimento decide o quanto do estado da célula anterior deve ser retido. O portão de saída determina o quanto do valor calculado da célula irá seguir na rede para as próximas células, filtrando o que deve ser exposto.




Figura 2 – Arquitetura de uma rede LSTM. Fonte: (MIENYE; SWART; OBAIDO, 2024).

Esses três portões são calculados da seguinte forma:

$$i_t = \sigma(W_{xi} x_t + W_{hi} h_{t-1} + b_i) \quad (4)$$

$$f_t = \sigma(W_{xf} x_t + W_{hf} h_{t-1} + b_f) \quad (5)$$

$$o_t = \sigma(W_{xo} x_t + W_{ho} h_{t-1} + b_o) \quad (6)$$

Onde x_t é entrada no instante t , os parâmetros W são as matrizes de pesos, os parâmetros b são os vieses, σ é a função de ativação sigmóide, h_{t-1} e C_{t-1} são as saídas da célula anterior.

A porta de entrada é representada por i_t , que controla o quanto da nova entrada x_t é escrita na célula C_t . O portão de esquecimento representado por f_t , decide o quanto da célula antiga C_{t-1} deve ser retido. Por fim, a porta de saída representada por o_t , determina o quanto da célula de estado C_t é usada para calcular o estado oculto h_t .

A recorrência interna na célula LSTM é controlada pelo estado da célula C_t , que funciona como uma esteira levando informações relevantes entre os passos de tempo. Esse mecanismo garante que a LSTM mantenha e atualize a memória ao longo da sequência, capturando dependências longas de forma eficiente.

Além disso, as operações de multiplicação que ocorre nos cálculos das portas e suas respectivas entradas garantem que as interações entre os diferentes componentes da LSTM sejam suaves e eficientes. Isso permite que a LSTM realize transformações complexas nos dados de entrada, mantendo ao mesmo tempo a estabilidade do processo de aprendizado.

O uso desses mecanismos permite que as redes LSTM lembrem ou esqueçam seletivamente informações, capacitando-as a lidar com dependências de longo prazo de forma mais eficaz do que as RNNs tradicionais.

2.2.4. BILSTM

A *Bidirectional Long Short-Term Memory* (BiLSTM), também é uma evolução da RNN, uma extensão com base na LSTM. A principal inovação do Bidirectional LSTM é a sua capacidade de processar informações em ambas as direções, ou seja, da esquerda para a direita e da direita para a esquerda, o que resulta em uma compreensão mais contextualizada das informações (MIENYE; SWART; OBAIDO, 2024). A estrutura do BiLSTM consiste em duas camadas LSTM separadas, uma que lê a sequência de entrada na ordem normal e outra que a lê na ordem reversa, conforme ilustrado na Figura 3. Após isso, o modelo combina os resultados em uma função de ativação. Essa configuração permite que a rede capture informações contextuais que podem estar presentes em diferentes partes da sequência, conseguindo

aprender relações complexas de maneira mais eficaz. Com essa abordagem bidirecional, a rede captura detalhes das sequências que podem não ser capturados em uma abordagem unidirecional.




Figura 3 – Arquitetura de uma rede BiLSTM. Fonte: (MIENYE; SWART; OBAIDO, 2024).

Apesar das vantagens da BiLSTM, seus principais desafios estão associados à elevada complexidade do modelo, que implica maior consumo de recurso computacional e de memória. É importante destacar que, em alguns casos, o aumento da complexidade não resulta em melhor desempenho, devendo a adequação do modelo ser avaliada conforme o contexto da aplicação.

3. TRABALHOS RELACIONADOS

Esta seção aborda uma revisão da literatura recente sobre o uso de modelos de aprendizado profundo na previsão de chuva. A seguir, são apresentados quatro estudos representativos que ilustram diferentes abordagens aplicados ao problema de previsão de precipitação em diversos contextos geográficos.

3.1. IMPACT OF PRECIPITATION EXTREMES ON ENERGY PRODUCTION ACROSS THE SÃO FRANCISCO RIVER BASIN, BRAZIL

Os autores em (SANTOS; JUSTINO; RODRIGUES, 2024) analisam uma relação entre eventos climáticos extremos e os impactos relevantes no ciclo hidrológico, ou seja, analisar se eventos climáticos de precipitação extrema ocorrendo na bacia do rio São Francisco podem impactar as variáveis energéticas no período de 2000 a 2019. Os autores utiliza algoritmos de aprendizado de máquina para desenvolver um modelo conceitual capaz de relacionar índices climáticos e variáveis energéticas.

Para realizar esse estudo, o autor selecionou os seguintes informações: Energia Natural Afluente (ANE) e Energia Armazenada (STE). Esses dados estão dispo-

nibilizados diariamente através do banco de dados do ONS (Operador Nacional do Sistema Elétrico) que possui registros desde o ano 2000 até os dias atuais. Ademais, os dados climáticos utilizados foram selecionados de duas fontes: o banco de dados BR-DWGD ³, com frequência diária, e o ERA5 ⁴, com frequência de hora em hora. Subsequentemente, ambos os conjuntos de dados foram coletados em uma área do rio São Francisco, utilizando um filtro com base na latitude e longitude.

Nesse contexto, o autor usufruiu dos métodos de aprendizado de máquina e redes neurais profundas, os quais são: *Random Forest*, Rede Neural Artificial e *k-Nearest Neighbors*. O trabalho selecionou um método de *GridSearchCV* para escolher os melhores parâmetros para o modelo de regressão, em busca dos melhores resultados. Para avaliar a precisão do modelo de regressão proposto, foram utilizadas quatro métricas de erro: Erro Absoluto Médio (MAE), Erro Percentual Absoluto Médio (MAPE), Raiz do Erro Quadrático Médio (RMSE) e o Coeficiente de Eficiência Kling-Gupta (KGE). Os resultados foram obtidos a partir da base de dados de chuva e do modelo proposto para prever uma das variáveis energéticas. Nos resultados, o *Random Forest* apresentou o melhor desempenho na maioria dos casos.

3.2. A DEEP LEARNING MODEL FOR PRECIPITATION NOWCASTING USING DATA FUSION

Em (CRUZ *et al.*, 2024), a autora estuda o uso de uma CNN (Rede Neural Convolutiva), devido à capacidade de apresentar características espaço-temporais, com o uso de um módulo de fusão de dados para prever a precipitação em uma região da Holanda.

A autora desenvolveu um módulo de fusão de dados, ou seja, uma combinação dos canais de entrada para condensar informações temporais em um único mapa de características, com objetivo de facilitar o processamento posterior, porém, mantendo os dados mais relevantes sobre a precipitação. O trabalho analisou a acurácia, precisão, sensibilidade e índice de sucesso crítico.

O modelo selecionado foi o SmaAt-UNet, uma arquitetura de rede neural profunda baseada na U-Net, otimizada para segmentação de imagens e equipada com um módulo de fusão de dados, utilizando apenas imagens como entrada. A base de dados é composta por imagens de uma região da Holanda registradas a cada 5 minutos, de 2016 a 2019. Em todas as métricas de avaliação, os resultados foram superiores com o uso do módulo de fusão e, adicionalmente, o tempo de classificação foi reduzido, evidenciando a eficiência da abordagem.

³ <https://sites.google.com/site/alexandrecandidoxavierufes/brazilian-daily-weather-gridded-data>

⁴ <https://cds.climate.copernicus.eu/datasets/reanalysis-era5-single-levels?tab=overview>

3.3. GREEN AI APLICADA AO NOWCASTING: UM ESTUDO COM MODELOS RECORRENTES OTIMIZADOS

Os autores em (BRUM *et al.*, 2025) direcionaram-se a um estudo de predição de chuvas extremas por meio de modelos de aprendizado de máquina de forma sustentável com entradas sendo imagens. O autor propôs o uso de três modelos para realizar essa análise: PredRNN-V2, MotionRNN e ConvLSTM, em suas respectivas versões multiescalas, com uso do *framework* MS-RNN. Esse *framework* foi originalmente proposto por (MA; ZHANG; LIU, 2024), com o objetivo de reduzir o uso de memória e complexidade computacional, mantendo as eficiências dos modelos. Por isso, o autor aplica uma metodologia em que analisa o consumo de energia, uso de água e emissões de CO2 equivalentes dos diferentes modelos citados.

Nessa pesquisa, o conjunto de dados climáticos utilizados, foram: TAASRAD19, com os dados representados como imagens bidimensionais (2D), considerando a refletividade máxima na seção vertical com uma taxa de amostragem de 5 minutos, cobrindo uma área de 240 km de diâmetro e resolução horizontal de 500 m⁵ e um conjunto de dados extraídos do radar meteorológico, operado pelo Instituto Estadual do Ambiente (INEA), em uma região da cidade do Rio de Janeiro⁶.

Em relação a avaliação da precisão dos modelos, o autor utilizou algumas métricas de desempenho para avaliar a acurácia dos modelos, os quais foram: SSIM (*Structural Similarity Index*), o qual mede a similaridade estrutural entre duas imagens, o quanto maior for o valor dessa medida mais próxima a imagem de precipitação prevista e a observada, CSI (*Critical Success Index*), o qual compara o número de acertos e erros de um modelo quando ele tenta prever a ocorrência de uma precipitação, o quanto mais próximo do um (1) essa medida melhor a previsão.

Além dessas, foram utilizadas quatro métricas principais para avaliar os erros do modelo: MSE e MAE, que medem a média da diferença entre os valores previstos e reais. Além disso, foram consideradas as versões balanceadas dessas métricas (B-MSE e B-MAE), que atribuem mais peso aos erros nas regiões com chuvas intensas, permitindo avaliar melhor a capacidade do modelo de prever eventos extremos. Para todas essas métricas, valores mais próximos de zero indicam maior eficácia do modelo.

Em relação aos resultados e experimentos, tanto com os dados extraídos pelo INEA quanto com os do TAASRAD19, o uso do *framework* MS-RNN com os três modelos citados reduziu o consumo de memória, o tempo de execução e a energia utilizada. Além disso, os modelos foram avaliados quanto às estimativas de emissões de CO2 e consumo de água usando a biblioteca CodeCarbon, e, de forma consistente com a análise anterior, essas estimativas foram reduzidas com o uso

⁵ <<https://github.com/MPBA/TAASRAD19?tab=readme-ov-file>>

⁶ <<https://rionowcast.dexl.incc.br/>>

do *framework*. Em termos de acurácia preditiva na base TAASRAD19, os modelos com o *framework* MS-RNN apresentaram desempenho igual ou superior aos modelos tradicionais, mantendo a acurácia preditiva enquanto reduzem consumo de memória, energia, emissões de (CO₂eq) e água.

3.4. APPLICATION OF LONG SHORT-TERM MEMORY (LSTM) NETWORK FOR SEASONAL PREDICTION OF MONTHLY RAINFALL ACROSS VIETNAM

Em (NGUYEN-DUC *et al.*, 2024) os autores buscam encontrar à previsão de precipitação com antecedência de até 6 meses em sete regiões do Vietnã, um país que sofre com chuvas extremas em determinadas épocas do ano, principalmente, por causa de um sistema de monções que afeta todos os países da Ásia. Os autores optaram por utilizar uma rede neural recorrente do tipo LSTM (*Long Short-Term Memory*) para analisar a previsão de precipitação no Vietnã. A pesquisa utiliza diversos índices de variáveis além da chuva, como: temperatura da superfície do mar (SST) em áreas específicas do Pacífico e do Atlântico, vento zonal em altos e médios níveis sobre o Pacífico, ligadas à circulação tropical e à modulação de chuva, entre outros.

Com isso, treinou-se o modelo com dados de diversos índices climáticos coletados normalizados com o *MinMaxScaler* de sete sub-regiões do Vietnã de 1980 até 2016 para o treinamento e de 2017 até 2020 para validação do modelo. Além disso, os valores ausentes foram preenchidos usando uma relação não linear com base nos 15 valores anteriores, por meio do estimador *k-Nearest Neighbors* (KNN). Para avaliar o modelo, mediu-se algumas métricas de regressão das estações observadas, como: o RMSE, MAE e *Correlation coefficient* (CORR), que é uma medida estatística que indica a força e a direção da relação linear entre duas variáveis, variando de -1 (relação negativa perfeita) a 1 (relação positiva perfeita).

Em relação aos resultados, o modelo foi aplicado em três base de dados distintas para avaliar as métricas de erro e todas as estações meteorológicas testadas apresentaram um bom resultado. Esse estudo mostrou que o modelo conseguiu capturar padrões sazonais e estruturas climáticas complexas em mais de 100 estações meteorológicas do Vietnã.

4. METODOLOGIA

A metodologia abordada nesse estudo tem como foco realizar a previsão de chuva na cidade do Rio de Janeiro a partir de séries espaço-temporais obtidas por um radar meteorológico. Nessa tarefa, os modelos recebem como entrada uma sequência de dados de chuva e devem estimar a evolução da precipitação nos quadros futuros, preservando padrões temporais relevantes para a detecção de precipitações.

Primeiramente, será apresentado como foi coletado os dados. Após isso, é exposto o pré-processamento realizados nos dados. Por fim, é descrito as métricas de avaliação que são utilizadas nos resultados.

4.1. COLETA DE DADOS

Neste estudo, foram usados dados de duas fontes abertas: BrDwgd e Merge. Ambas disponibilizam informações diárias de precipitação referentes a diferentes períodos. A seguir, é apresentado as principais características de cada base e explicado como os dados estão organizados.

4.1.1. Brazilian Daily Weather Gridded Data

O *Brazilian Daily Weather Gridded Data* (BR-DWGD) ⁷ é uma base de dados com informações do clima brasileiro desde 1961. Os dados observados foram coletadas diaramente por 11,473 pluviômetro e 1,252 estações climáticas espalhadas pelo território brasileiro. As informações que são disponibilizadas, são: precipitação (mm), máxima e mínima temperatura (°C), radiação solar (MJ/m²), humidade relativa (%), velocidade do vento à 2 metros(m/s) e evapotranspiração (mm). Além disso, disponibiliza as informações de latitude, longitude e um id para as estações.

As informações são fornecidas em um arquivo (.npz) para cada uma das variáveis comentadas. Foi feito um *script* em *Python*, em que coleta as informações desses arquivos, atribui uma máscara para selecionar as estações pertencentes na região do Rio de Janeiro e selecionado uma estação para seguir no processamento. A estação meteorológica escolhida localiza-se na latitude -22,86138916 e longitude -43,4113884, situada em Deodoro, um bairro da Zona Oeste do Rio de Janeiro. O conjunto de dados apresenta uma série histórica de chuva entre os anos de 2008 e 2024, totalizando aproximadamente 5.000 registros diários

4.1.2. Merge

O Merge ⁸ é uma base de dados de precipitação sobre a América do Sul, desenvolvida pelo Instituto Nacional de Pesquisas Espaciais (INPE). A série combina estimativas de chuva baseadas em satélite com observações feitas em superfície, proporcionando dados diários de precipitação (mm) de diversas áreas.

As informações são coletadas em arquivos (.grib2), que armazenam dados de precipitação de diversas estações para cada dia. Foi criado um *script* em *Python* para automatizar o processo de baixar os arquivos diretamente do site. Posteriormente, realiza-se o processamento desses dados, aplicando uma máscara para limitar uma área do Rio de Janeiro, extraíndo apenas os valores de um ponto geográfico.

⁷ <https://sites.google.com/site/alexandrecandidoxavierufes/brazilian-daily-weather-gridded-data>

⁸ https://data.inpe.br/stac/browser/collections/prec_merge_daily-1?.language=en

Esse ponto escolhido localiza-se na latitude -23,05 e longitude -43,65, situada em Marambaia, um bairro da Zona Oeste do Rio de Janeiro. O conjunto de dados apresenta uma série histórica de precipitação entre os anos de 1998 e 2025, totalizando aproximadamente 10.000 registros diários.

4.2. TRATAMENTO DE DADOS

Os dados coletados estão organizados em uma matriz, onde cada linha corresponde aos dias do período analisado e as colunas armazenam as informações de uma estação na área do Rio de Janeiro. No último experimento, é usado outras variáveis meteorológicas, além da precipitação, que são: temperatura máxima e mínima, radiação solar, humidade relativa e velocidade do vento à 2 metros. Essas *features* estão presentes na base de dados do BR-DWGD. O objetivo de acrescentar esses novos dados é analisar a previsão dos modelos. Todas essas informações são numéricas e existiam alguns dias com dados faltantes, que foram substituídos por zero.

Ademais, os dados foram normalizados com transformador *MinMaxScaler*, que normaliza os valores em um intervalo de $[0,1]$, com a seguinte equação:

$$\hat{x}_i = \frac{x_i - \min(x)}{\max(x) - \min(x)} \quad (7)$$

O *MinMaxScaler* subtrai o valor em questão pelo menor valor da coluna e então divide pela diferença entre o valor máximo e mínimo. Essa técnica coloca todas as variáveis na mesma escala num intervalo fixo, o que ajuda modelos de série temporal a treinarem de forma mais estável, evitando que valores extremos influenciem negativamente na etapa do aprendizado.

4.3. MODELOS DE ANÁLISE DE SÉRIE TEMPORAL

Nessa pesquisa foram utilizados três soluções de aprendizado de máquina, LSTM, Bi-LSTM e RandomForest. O ARIMA, modelo estatístico, foi utilizado para comparar com as soluções encontradas com os demais.

O LSTM e o Bi-LSTM são modelos de redes neurais recorrentes que são utilizados com frequência em problemas de séries temporais e foram detalhados na Seção 2.2.2. A topologia dessas 2 redes neurais consiste em 2 camadas ocultas com 32, 64, 128 ou 256 neurônios artificiais. Em cada experimento avaliou-se com diferentes configurações, utilizando a configuração que obteve o menor valor de erro.

O RF (*Random Forest*) é um modelo de aprendizado de máquina composto por várias árvores de decisão que fazem previsões de forma independente e combinam seus resultados, tornando o modelo mais robusto e menos suscetível a erros individuais. Analisar RF em previsões de uma série temporal de chuva é interessante, pois, ele consegue lidar bem com dados complexos e identificar relações não

lineares entre as variáveis. Além disso, esse modelo é resistente a ruídos e dados considerados extremos (*outliers*).

Contudo, uma limitação dos modelos de RF é a baixa interpretabilidade, isto é, o RF toma decisões com base em inúmeras árvores, dificultando entender exatamente por que o modelo chegou a determinada conclusão. Além disso, uma outra limitação é o fato do alto teor computacional, como o algoritmo cria várias árvores, pode ser pesado na hora do treinamento e na hora de realizar as previsões.

O ARIMA (*AutoRegressive Integrated Moving Average*) é um modelo estatístico para previsão de séries temporais que combina três componentes: o autorregressivo, que utiliza valores passados para prever o futuro, o integrado, que transforma a série em estacionária ao eliminar tendências e o de médias móveis, que ajusta a previsão considerando erros anteriores. Sua principal vantagem é capturar padrões de dependência temporal em dados históricos, tornando-o útil para prever chuva a partir de séries temporais.

Entretanto, um desafio dos modelos ARIMA é selecionar os valores ótimos para os parâmetros p , d e q , que representam a ordem dos componentes autorregressivo, integrado e média móvel, respectivamente. Não existe uma regra para definir os valores dessas variáveis. Nessa pesquisa foi escolhido alguns casos para selecionar essas variáveis. Um outro desafio que o ARIMA apresenta é a sensibilidade com valores extremos (*outliers*), que são valores que não seguem o padrão geral dos dados e podem distorcer a estimativa e a previsão do modelo.

4.4. EXPERIMENTOS

Nesta pesquisa, foram realizados três experimentos. Inicialmente, os modelos foram avaliados utilizando apenas a série histórica de precipitação em seu formato bruto (sem tratamento) para cada base de dados. No segundo experimento, manteve-se o foco exclusivo nos dados pluviométricos, porém aplicando técnicas de normalização do *MinMaxScaler* durante o treinamento. Por fim, o terceiro experimento expandiu a análise para uma abordagem multivariada, incorporando variáveis climáticas adicionais, como temperaturas mínima e máxima e velocidade do vento, sendo esta etapa aplicada exclusivamente à base de dados BR-DWGD.

4.5. MÉTRICAS DE AVALIAÇÃO

Como métrica para avaliar o modelo foi utilizado o MSE (*Mean Squared Error*) (2), RMSE (*Root Mean Squared Error*) e MAE (*Mean Absolute Error*) (4), conforme as fórmulas:

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (8)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (9)$$

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (10)$$

Cada erro calculado considera n o número de amostras para testes, no caso dessa pesquisa $n = 30$, y_i o valor observado de chuva e $\hat{y}_i$ o valor previsto pelos modelos. Os erros medem o quão distante, em média, estão os valores previstos dos valores reais. O MSE é útil quando queremos penalizar valores altos de erro, pois, no cálculo a diferença é elevada ao quadrado. O RMSE é, simplesmente, a raiz quadrada do MSE, por isso, trazendo o erro estimado de volta à escala original dos dados. O RMSE se torna mais fácil de interpretar do que o MSE. Além desses, o MAE calcula a média das diferenças absolutas entre os valores reais e previstos, considerando só o valor do erro e não sua direção. Todos esses erros estão na unidade da chuva, em milímetros (mm).

Outra métrica importante em meteorologia é o CSI (*Critical Success Index*), usada para avaliar o desempenho do modelo na previsão de chuva. O CSI considera os acertos (chuvas corretamente previstas), os falsos alarmes (chuvas previstas, mas que não ocorreram) e os falsos negativos (chuvas que aconteceram, mas não foram previstas), sendo definido por:

$$\text{CSI} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}} \quad (11)$$

Onde TP são os acertos (chuvas previstas e que realmente ocorreram), FP são os falsos positivos (chuvas previstas, mas que não aconteceram) e FN são os falsos negativos (chuvas que aconteceram, mas não foram previstas). Nesse estudo, foi calculado o CSI com um limiar de 1 mm/dia.

Durante o treinamento dos modelos do LSTM e BiLSTM, utiliza-se uma função de perda composta pela soma do MSE e da MAE, conforma a equação:

$$\text{LOSS} = \text{MSE} + \text{MAE} \quad (12)$$

Essa função de perda coletou-se do estudo do (BRUM *et al.*, 2025), que tem como objetivo ajustar os pesos sinápticos durante a fase de treinamento em cada iteração. Por isso, esse formato busca unir a sensibilidade do MSE, que penaliza fortemente os erros grandes, com a estabilidade do MAE, que é menos afetado por variações e valores discrepantes.

5. EXPERIMENTOS E RESULTADOS

Esta seção apresenta os resultados obtidos pelos experimentos com os dados obtidos do BR-DWGD e MERGE. Foram realizados três experimentos, que serão descritos em detalhes ao longo desta seção. Em primeiro plano, será apresentado as configurações da máquina, onde os experimentos foram executados, e dos hiper-parâmetros que foram utilizados nesta pesquisa. Após isso, são apresentados os resultados dos erros de predição em cada teste. Por fim, são exibidas as métricas de desempenho e os valores de consumo de energia obtidos.

5.1. CONFIGURAÇÕES DO AMBIENTE

Os experimentos foram executados na máquina da Universidade Federal Fluminense (UFF) do laboratório LabIC equipada com um processador Intel Core i7-10700, com 8 núcleos e 16 threads, acompanhada de 16 GB de memória RAM. Além de uma GPU NVIDIA GeForce RTX 3060 com 12 GB de memória dedicada. O sistema operacional utilizado foi o Ubuntu 22.04.5 LTS. O uso de GPU foi necessário para o treinamento dos modelos, visto que, o pacote torch utilizado para esse estudo requer processamento por GPU.

5.2. HIPER-PARÂMETROS

Além dessas configurações, existem alguns outros ajustes realizados no código para ajustar o modelo na busca de uma eficácia melhor. O tamanho do lote (*batch size*) determina quantos registros são utilizados para calcular o erro e atualizar os parâmetros em cada iteração. O tamanho da janela (*lookback*) é a quantidade de registros passados, que são utilizados como entrada, para prever o próximo valor de uma série temporal. A taxa de aprendizado (*learning rate*), em que é utilizada no LSTM e no BiLSTM, controla o tamanho dos passos dados durante a atualização dos pesos da rede a cada iteração do treinamento. O número de épocas são quantas iterações são realizadas para o treinamento dos dados. Na Tabela 1, é apresentado os valores dessas variáveis adotados nessa pesquisa.

Tabela 1 – Hiper-parâmetros dos modelos de aprendizado de máquina LSTM e BiLSTM

Configuração	Valor
tamanho do lote	32
tamanho da janela	30
taxa de aprendizado	0,001
épocas	500

Em séries temporais, uma janela é uma técnica que consiste em dividir os dados em segmentos de tamanho fixo, que representam a quantidade de registros

passados utilizados como entrada para prever o próximo valor. Quando essas janelas são aplicadas com sobreposição, significa que cada nova janela compartilha parte dos dados com a anterior, garantindo continuidade e evitando perda de informação entre os blocos. Essa abordagem é especialmente útil para capturar padrões temporais.

Por exemplo, considere uma série de precipitação diária: $[0, 0, 0, 20, 5, 0]$ (em mm). Se definirmos uma janela de tamanho 3 com sobreposição, as janelas serão formadas assim:

1. Janela 1: $[0, 0, 0]$, próximo valor a prever: 20;
2. Janela 2: $[0, 0, 20]$, próximo valor: 5;
3. Janela 3: $[0, 20, 5]$, próximo valor: 0.

Observa-se que as janelas compartilham valores com a anterior, caracterizando a sobreposição. O alvo é sempre o primeiro ponto fora da janela, usado para previsão.

Os últimos 30 dias de cada base foram separados para teste, ou seja, são o período em que os modelos fazem a previsão de chuva. Como se tratam de pontos diferentes na cidade do Rio de Janeiro, os erros obtidos são distintos: no BR-DWGD, esse período inclui chuvas mais intensas, enquanto no MERGE prevalecem dias com chuvas mais fracas. O restante dos dias de cada base de dados foi utilizado na etapa de treinamento dos algoritmos de aprendizado de máquina.

O fluxo consistiu em treinar cada modelo com os dados de cada base e, na etapa de teste, utilizar o modelo resultante da última época de treinamento para gerar as previsões de chuva, a partir das quais foram calculadas as métricas de erro e construídos os gráficos apresentados nesta seção. Todo o código desenvolvido nessa pesquisa está disponível no repositório *github*⁹. Os modelos de LSTM e BiLSTM utilizados foram obtidos da biblioteca *PyTorch*, o ARIMA da biblioteca *statsmodels* e o *Random Forest* da biblioteca *ScikitLearn*. Para a avaliação dos erros, foram utilizadas as métricas de MSE e MAE da biblioteca *ScikitLearn*, a medição de tempo foi realizada com a biblioteca *time*, a construção de gráficos foi realizado com a biblioteca *matplotlib* e, por fim, as estimativas de consumo energético e emissões de carbono foram obtidas por meio da biblioteca *CodeCarbon*.

5.3. AVALIAÇÃO DE QUALIDADE DOS MODELOS

Nessa seção são demonstrados os resultados das métricas de avaliação com diferentes modelos nas duas bases de dados. Primeiro, analisaremos os erros médios obtidos. Após isso, analisaremos o tempo de treinamento, juntamente, com o quanto

⁹ <https://github.com/pedrobseximenes/tcc>

de energia gastou-se. Os resultados nas tabelas subsequentes são obtidos por uma média de dez execuções.

5.3.1. Resultados de Erro de Predição

O primeiro experimento foi realizado com os dados de chuva da base de dados sem pré-processamento, ou seja, sem aplicar a normalização dos dados. A Tabela 2 apresenta os resultados dos experimentos realizados com a base de dados do BR-DWGD. Os modelos LSTM e BiLSTM obtiveram os menores valores de MAE, o que mostra uma maior proximidade da previsão com o valor real. Além disso, o BiLSTM apresentou a melhor taxa do CSI, isto é, foi o modelo que mais acertou a ocorrência de chuva nos dias em que realmente choveu. Nesse experimento, os modelos LSTM e BiLSTM apresentaram os menores erros quando configurados com 64 neurônios em cada camada oculta. Na Figura 4, os modelos LSTM e BiLSTM conseguem prever alguns casos com pico de chuva, enquanto o ARIMA e *Random Forest* aproximam de uma previsão mais linear da chuva.

Tabela 2 – Métricas dos modelos com dados desnormalizados do BR-DWGD

Modelo	MAE	MSE	RMSE	CSI
LSTM	$6,299 \pm 1,094$	$158,128 \pm 39,62$	$12,48 \pm 1,628$	$0,193 \pm 0,052$
BiLSTM	$6,262 \pm 1,116$	$162,815 \pm 42,205$	$12,666 \pm 1,632$	$0,219 \pm 0,056$
ARIMA	7,341	175,733	13,256	0,200
Random Forest	7,674	166,265	12,894	0,200




Figura 4 – Exemplo da previsão com dados desnormalizados do BR-DWGD. O LSTM e BiLSTM com 64 neurônios. O eixo X representa o tempo em dias e o eixo Y representa a precipitação acumulada (mm).

Na Tabela 3, é apresentado os resultados dos experimentos realizados com a base de dados do Merge. Nesse cenário, os modelos LSTM e BiLSTM apresentaram os menores valores de MAE, indicando previsões numericamente mais próximas dos

valores observados de chuva. Por outro lado, o modelo ARIMA obteve o maior valor de CSI, entretanto, na Figura 5 observa-se que a previsão gerada pelo ARIMA não reproduz adequadamente o comportamento observado da chuva. Com o MERGE, os modelos LSTM e BiLSTM apresentaram os menores erros quando configurados com 256 e 64 neurônios em cada camada oculta, respectivamente.

Tabela 3 – Métricas de qualidade dos modelos com dados desnormalizados do MERGE.

Modelo	MAE	MSE	RMSE	CSI
LSTM	$1,832 \pm 0,307$	$11,862 \pm 3,636$	$3,411 \pm 0,503$	$0,162 \pm 0,098$
BiLSTM	$1,691 \pm 0,223$	$10,925 \pm 2,087$	$3,291 \pm 0,322$	$0,098 \pm 0,077$
ARIMA	2,576	9,023	3,004	0,200
Random Forest	1,99	9,241	3,04	0,190




Figura 5 – Exemplo da previsão com dados desnormalizados do MERGE. O LSTM e BiLSTM com 64 neurônios. O eixo X representa o tempo em dias e o eixo Y representa a precipitação acumulada (mm).

Mesmo usando apenas o histórico de chuva em um único ponto do Rio de Janeiro, os modelos alcançaram erros razoáveis, com possíveis ajustes a serem feitos para melhorar as métricas. LSTM e BiLSTM geraram séries mais próximas do comportamento real, com períodos sem chuva seguidos por picos de chuva, enquanto ARIMA e *Random Forest* tenderam a produzir respostas quase lineares, sem representar bem essa variabilidade, mesmo com valores de erro tão próximos. Os experimentos subsequentes focam em analisar as variações para verificar o comportamento dos resultados obtidos.

O segundo experimento foi realizado com os dados de chuva normalizados, ou seja, coletados e transformados com o *MinMaxScaler*, em que define um intervalo de 0 e 1. O algoritmo do *Random Forest* não faz sentido realizar o experimento com os dados normalizados, por isso, foi apenas executado com os dados desnormalizados.

A Tabela 4 apresenta os resultados dos experimentos realizadas com a base de dados do BRDWGD. Com os dados normalizados no treinamento, os modelos de aprendizado profundo tiveram um desempenho inferior ao ARIMA em termos do erro quadrático (MSE/RMSE), mas superaram em relação ao MAE. O CSI para os modelos de redes neurais ficou zerado nas configurações específicas, enquanto ARIMA manteve 0,200. As melhores configurações dos modelos LSTM e BiLSTM foram com 256 e 64 neurônios em cada camada, respectivamente.

Tabela 4 – Métricas dos modelos com dados normalizados do BR-DWGD.

Modelo	MAE	MSE	RMSE	CSI
LSTM	$5,679 \pm 0,130$	$209,271 \pm 1,616$	$14,466 \pm 0,056$	$0,000 \pm 0,000$
BiLSTM	$5,717 \pm 0,253$	$210,209 \pm 3,201$	$14,498 \pm 0,115$	$0,000 \pm 0,000$
ARIMA	7,410	178,450	13,359	0,200

Uma diferença entre os experimentos é que, quando os dados foram normalizados com a mesma configuração usada para treinar os modelos de aprendizado profundo, as redes não conseguiram reproduzir bem os extremos, gerando apenas picos diários de chuva mais fracos, como mostrado na Figura 7. Já no primeiro experimento com dados desnormalizados (Figura 6), o modelo aprendeu melhor o padrão da série, produzindo picos diários mais intensos e mais próximos do comportamento real.




Figura 6 – Exemplo da previsão com dados desnormalizados no treinamento do LSTM com 256 neurônios e na base de dados do BR-DWGD.

Na Tabela 5, é apresentado os resultados dos experimentos realizados com a base de dados do Merge. Com os dados normalizados no treinamento, os modelos de aprendizado profundo tiveram um desempenho inferior ao ARIMA em termos do erro quadrático (MSE/RMSE), mas superaram em relação ao MAE. O CSI para os modelos de redes neurais ficou menor que do ARIMA, que manteve 0,200, semelhante aos resultados com o BR-DWGD. O CSI diminuiu para o LSTM, mas aumentou para o BiLSTM. As melhores configurações dos modelos LSTM e BiLSTM foram com 64 e 32 neurônios em cada camada, respectivamente.




Figura 7 – Exemplo da previsão com dados normalizados no treinamento do LSTM com 256 neurônios e na base de dados do BR-DWGD.

Tabela 5 – Métricas de qualidade dos modelos com dados normalizados do MERGE.

Modelo	MAE	MSE	RMSE	CSI
LSTM	$1,417 \pm 0,044$	$10,345 \pm 0,155$	$3,216 \pm 0,024$	$0,133 \pm 0,048$
BiLSTM	$1,449 \pm 0,027$	$10,464 \pm 0,091$	$3,235 \pm 0,014$	$0,134 \pm 0,009$
ARIMA	2,591	9,107	3,018	0,200




Figura 8 – Exemplo da previsão com dados normalizados no treinamento do BR-DWGD. O LSTM e BiLSTM com 64 neurônios. O eixo X representa o tempo em dias e o eixo Y representa a precipitação acumulada (mm).

A Figura 8 e a Figura 9 apresentam as predições do segundo experimento com a base de dados BR-DWGD e MERGE, respectivamente. Observa-se que tanto o LSTM quanto o BiLSTM geram pequenos picos de chuva, sem prever os eventos mais intensos e o ARIMA manteve um comportamento muito semelhante ao obtido com os dados sem normalização.

O último experimento foi executado com os dados de chuva da base do BR-DWGD com novas *features*. A Tabela 6 apresenta os resultados desse experimento com os modelos LSTM e BiLSTM. Novas informações do ambiente foram acrescentadas, os quais são: temperatura máxima e mínima, radiação solar, humidade




Figura 9 – Exemplo da previsão com dados normalizados no treinamento do MERGE. O LSTM e BiLSTM com 64 neurônios. O eixo X representa o tempo em dias e o eixo Y representa a precipitação acumulada (mm).

relativa e velocidade do vento à 2 metros. Com esses novos dados, os modelos apresentaram erros maiores comparado com os experimentos anteriores. A Figura 10 demonstra que os modelos acertam a maioria dos dias que choveu, mas, prevêem mais dias com precipitação, o que não existe nos dados observados. As melhores configurações dos modelos LSTM e BiLSTM foram com 64 e 32 neurônios em cada camada, respectivamente.

Tabela 6 – Métricas de qualidade dos modelos com novos atributos do BR-DWGD.

Modelo	MAE	MSE	RMSE	CSI
LSTM	$8,906 \pm 1,636$	$255,263 \pm 73,701$	$15,826 \pm 2,307$	$0,170 \pm 0,055$
BiLSTM	$8,485 \pm 1,625$	$257,454 \pm 76,761$	$15,894 \pm 2,316$	$0,218 \pm 0,046$




Figura 10 – Exemplo da previsão com novos atributos do BR-DWGD. O LSTM e BiLSTM com 64 neurônios. O eixo X representa o tempo em dias e o eixo Y representa a precipitação acumulada (mm).

5.3.2. Resultados de Desempenho e Energia

A Tabela 7 apresenta os resultados dos tempos de treinamento dos modelos com a base de dados do BRDWGD do primeiro experimento realizado, com os dados de chuva desnormalizados. O tempo de treinamento está em minutos, a pegada de carbono está em quilograma (*kg*) e energia consumida em kilowatts (*kWh*). Os resultados do LSTM e BiLSTM referem-se à melhor configuração identificada na seção anterior. No aspecto de emissão de carbono e consumo de energia, o RF apresentou os menores valores, porém, todos os modelos registraram níveis muito baixos nesses indicadores. Em relação ao tempo de treinamento, o BiLSTM apresentou o maior tempo de execução.

Tabela 7 – Resultado de Tempo e Energia com dados desnormalizados do BRDWGD. Unidades de medida: tempo (min), pegada de carbono (kg) e energia (kWh).

Modelo	Tempo Treinamento	Pegada de Carbono	Energia consumida
LSTM	4,026	$9,09 \times 10^{-4}$	$9,24 \times 10^{-3}$
BiLSTM	4,553	$9,05 \times 10^{-4}$	$1,02 \times 10^{-2}$
ARIMA	4,3	$5,50 \times 10^{-3}$	$5,59 \times 10^{-2}$
Random Forest	1,046	$3,48 \times 10^{-4}$	$3,54 \times 10^{-3}$

A Tabela 8 apresenta os resultados dos experimentos realizados com a base de dados do Merge sem a normalização dos dados. O tempo de treinamento dos modelos com o MERGE foi maior, pois, existe uma diferença de 10 anos na janela de dados entre as bases, observou-se uma variação proporcional no tempo necessário para o processamento e treinamento dos algoritmos. O LSTM apresentou um tempo de treinamento mais demorado, pois a configuração com 256 neurônios apresentou o menor erro. O RF apresentou o menor tempo de treinamento nas 2 bases de dados.

Tabela 8 – Resultado de Tempo e Energia com dados desnormalizados do MERGE. Unidades de medida: tempo (min), pegada de carbono (kg) e energia (kWh).

Modelo	Tempo Treinamento	Pegada de Carbono	Energia consumida
LSTM	13,294	$2,64 \times 10^{-3}$	$2,68 \times 10^{-2}$
BiLSTM	8,242	$1,25 \times 10^{-3}$	$1,27 \times 10^{-2}$
ARIMA	6,67	$6,36 \times 10^{-3}$	$6,47 \times 10^{-2}$
Random Forest	3,257	$6,56 \times 10^{-4}$	$6,68 \times 10^{-3}$

Em relação ao segundo experimento (dados normalizados), as Tabelas 9 e 10 exibem os resultados dessas métricas com as bases de dados BR-DWGD e Merge, respectivamente. De modo geral, observa-se uma redução na maioria das variáveis tempo de treinamento, emissão de carbono e energia consumida, o que representa um resultado positivo.

Tabela 9 – Resultado de Tempo e Energia com dados normalizados do BRDWGD. Unidades de medida: tempo (min), pegada de carbono (kg) e energia (kWh).

Modelo	Tempo Treinamento	Pegada de Carbono	Energia consumida
LSTM	4,478	$7,35 \times 10^{-4}$	$7,47 \times 10^{-3}$
BiLSTM	4,212	$3,90 \times 10^{-4}$	$3,97 \times 10^{-3}$
ARIMA	4,53	$1,77 \times 10^{-3}$	$1,80 \times 10^{-2}$

Tabela 10 – Resultado de Tempo e Energia com dados normalizados do MERGE. Unidades de medida: tempo (min), pegada de carbono (kg) e energia (kWh).

Modelo	Tempo Treinamento	Pegada de Carbono	Energia consumida
LSTM	4,706	$4,17 \times 10^{-4}$	$4,24 \times 10^{-3}$
BiLSTM	6,164	$5,28 \times 10^{-4}$	$5,37 \times 10^{-3}$
ARIMA	1,43	$1,88 \times 10^{-3}$	$1,91 \times 10^{-2}$

A Tabela 11 apresenta o resultado do último experimento realizado com a base de dados BR-DWGD e com novos atributos. Mesmo com a inserção de novas informações, esse experimento apresentou o menor tempo de treinamento e os melhores resultados em termos de emissões de carbono e consumo de energia em relação a configuração do LSTM e BiLSTM.

Tabela 11 – Resultado de Tempo e Energia com novas *features* do BR-DWGD. Unidades de medida: tempo (min), pegada de carbono (kg) e energia (kWh).

Modelo	Tempo Treinamento	Pegada de Carbono	Energia consumida
LSTM	2,716	$2,46 \times 10^{-4}$	$2,50 \times 10^{-3}$
BiLSTM	3,543	$3,10 \times 10^{-4}$	$3,15 \times 10^{-3}$

6. CONCLUSÃO

Esta pesquisa analisou o uso de algoritmos de aprendizado de máquina e o ARIMA para prever a chuva na cidade do Rio de Janeiro, com diferentes bases de dados. Para isso, foi necessário a coleta de dados de estações meteorológicas na cidade do Rio de Janeiro e o pré-processamento dos dados de chuva com o *MinMaxScaler*. Após isso, analisou-se os resultados com cada algoritmo, exibindo gráficos do resultado das previsões e obtendo os erros de predição para cada base de dados. Por fim, exibiu-se os resultados das métricas de desempenho e energia.

Os resultados de erro nas duas bases confirmam que prever chuva é uma tarefa complexa. Mesmo assim, apenas com o histórico de precipitação foi possível

obter erros moderados e, em algumas configurações de LSTM e BiLSTM, previsões próximas às observadas. No segundo experimento, o uso de dados normalizados no treinamento não alterou significativamente as métricas, mas uma diferença qualitativa importante foi observada: o uso de dados sem normalização permitiu aos modelos representar com maior fidelidade os picos mais intensos de precipitação. Enquanto a normalização tende a suavizar valores extremos, os dados desnormalizados preservam a magnitude dos eventos de chuva forte. Já o terceiro teste, com algoritmos de aprendizado profundo e novos variáveis climáticas (temperatura máxima e mínima, velocidade do vento), apresentou desempenho semelhante aos anteriores, reforçando a dificuldade do problema.

Em relação as métricas de desempenho, todos os algoritmos apresentaram bons resultados de tempo de treinamento, energia consumida e pegada de carbono. Os tempos de treinamentos mais longos foram obtidos com configurações mais custosas computacionalmente, como é o caso do LSTM com 256 neurônios e 2 camadas ocultas. Como visto em Seções anteriores, os impactos negativos, principalmente da ação humana sobre a natureza, ressaltam a importância de uma análise com viés sustentável.

Como trabalhos futuros é possível aplicar outras técnicas que lidam melhor com dados esparsos, a ampliação dos testes com outras estações meteorológicas, isto é, usar mais de uma estação para prever a chuva, avaliar o desempenho de modelos mais avançados de IA, como arquiteturas baseadas em *autoencoders*, para captura de padrões mais complexos de precipitação e acrescentar novos índices climáticos extremos com base no relatório do Painel Intergovernamental sobre Mudanças Climáticas (IPCC) (IPCC, 2021), com informações quantidade de dias muito quentes/frios, quantidade de chuva máxima em 1 ou 5 dias, entre outros índices.

Referências

- BARCELLOS, P. da C. L.; CATALDI, M. Flash flood and extreme rainfall forecast through one-way coupling of wrf-smap models: Natural hazards in rio de janeiro state. *Atmosphere*, v. 11, n. 8, 2020. ISSN 2073-4433. Disponível em: <https://www.mdpi.com/2073-4433/11/8/834>.
- BOVE, R.; PELINO, V.; De Leonibus, L. Complexity in rainfall phenomena. *Communications in Nonlinear Science and Numerical Simulation*, v. 11, n. 6, p. 678–684, 2006. ISSN 1007-5704. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1007570404001248>.
- BRUM, D. *et al.* Towards sustainable nowcasting: Assessing the environmental costs of AI-driven extreme rainfall prediction. 2025.
- COSTA, J. M. F. d. *et al.* Trend analysis of precipitation extremes in brazil: the role of atmospheric temperature. *Revista Brasileira de Ciências Ambientais*, v. 60, p. e2123, Jun. 2025. Disponível em: https://www.rbciamb.com.br/Publicacoes_RBCIAMB/article/view/2123.
- CRUZ, A. L. Souza Castanheira da *et al.* A deep learning model for precipitation nowcasting using data fusion. In: *2024 IEEE International Conference on Multisensor Fusion and Integration for Intelligent Systems (MFI)*. [S.l.: s.n.], 2024. p. 1–6.
- FLECK, L. *et al.* Redes neurais artificiais: princípios básicos. *Revista Eletrônica Científica Inovação e Tecnologia*, v. 7, p. 47, 03 2016.
- FONSECA, A. *et al.* Analysis of precipitation data in rio de janeiro city using extreme value theory. In: *Anais Estendidos do XXXVII Simpósio Brasileiro de Bancos de Dados*. Porto Alegre, RS, Brasil: SBC, 2022. p. 193–198. ISSN 0000-0000. Disponível em: https://sol.sbc.org.br/index.php/sbbd_estendido/article/view/21864.
- HUANG, L. X.; ISAAC, G. A.; SHENG, G. Integrating nwp forecasts and observation data to improve nowcasting accuracy. *Weather and Forecasting*, American Meteorological Society, Boston MA, USA, v. 27, n. 4, p. 938 – 953, 2012. Disponível em: https://journals.ametsoc.org/view/journals/wefo/27/4/waf-d-11-00125_1.xml.
- IPCC. Annex vi: Climatic impact-driver and extreme indices [gutiérrez j.m., r. ranasinghe, a.c. ruane, r. vautard (eds.)]. In: _____. *Climate Change 2021: The Physical Science Basis. Contribution of Working Group I to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change*. Cambridge, United Kingdom and New York, NY, USA: Cambridge University Press, 2021. p. 2205–2214.
- IPCC. *Climate Change 2023: Synthesis Report. Contribution of Working Groups I, II and III to the Sixth Assessment Report of the Intergovernmental Panel on Climate Change*. Geneva, Switzerland: IPCC, 2023. 35–115 p. Disponível em: <https://www.ipcc.ch/report/ar6/syr/>.

- LEANDRO, A. F.; SANTOS, A. R.; PEREIRA, J. G. Redes neurais artificiais aplicadas na previsão de séries temporais: uma revisão bibliográfica. *Revista de Ciência e Tecnologia (RECIT)*, Universidade Tecnológica Federal do Paraná (UTFPR), v. 5, n. 2, p. 17–30, 2020. Disponível em: <http://bdta.ufra.edu.br/jspui/handle/123456789/1381>.
- MA, Z.; ZHANG, H.; LIU, J. Mm-rnn: A multimodal rnn for precipitation nowcasting. *IEEE Transactions on Geoscience and Remote Sensing*, v. 61, p. 1–14, 2023.
- MA, Z.; ZHANG, H.; LIU, J. *MS-RNN: A Flexible Multi-Scale Framework for Spatiotemporal Predictive Learning*. 2024. Disponível em: <https://arxiv.org/abs/2206.03010>.
- MIENYE, I. D.; SWART, T. G.; OBAIDO, G. Recurrent neural networks: A comprehensive review of architectures, variants, and applications. *Information*, v. 15, n. 9, 2024. ISSN 2078-2489. Disponível em: <https://www.mdpi.com/2078-2489/15/9/517>.
- NGUYEN-DUC, P. *et al.* Application of long short-term memory (LSTM) network for seasonal prediction of monthly rainfall across vietnam. *Earth Science Informatics*, Springer, v. 17, n. 5, p. 3925–3944, 2024. Disponível em: <https://doi.org/10.1007/s12145-024-01414-3>.
- SANTOS, J.; JUSTINO, F.; RODRIGUES, J. Impact of precipitation extremes on energy production across the São Francisco river basin, brazil. *Theoretical and Applied Climatology*, Springer, v. 155, n. 7, p. 6899–6916, 2024. Disponível em: <https://doi.org/10.1007/s00704-024-05051-0>.
- SILVA, S. T. da *et al.* Rainfall forecast in brazil using machine learning. *Chaos: An Interdisciplinary Journal of Nonlinear Science*, v. 35, n. 7, p. 073116, 07 2025. ISSN 1054-1500. Disponível em: <https://doi.org/10.1063/5.0259222>.
- Sistema Alerta Rio. *Termos meteorológicos - Sistema Alerta Rio*. 2025. <https://www.sistema-alerta-rio.com.br/previsao-do-tempo/termosmet/>. Acesso em: 2 nov. 2025.

APÊNDICE A - Lista de ilustrações

Figura 1 – Exemplo de arquitetura de uma rede RNN. Fonte: (MIENYE; SWART; OBAIDO, 2024).	10
Figura 2 – Arquitetura de uma rede LSTM. Fonte: (MIENYE; SWART; OBAIDO, 2024).	11
Figura 3 – Arquitetura de uma rede BiLSTM. Fonte: (MIENYE; SWART; OBAIDO, 2024).	13
Figura 4 – Exemplo da previsão com dados desnormalizados do BR-DWGD. O LSTM e BiLSTM com 64 neurônios. O eixo X representa o tempo em dias e o eixo Y representa a precipitação acumulada (mm).	23
Figura 5 – Exemplo da previsão com dados desnormalizados do MERGE. O LSTM e BiLSTM com 64 neurônios. O eixo X representa o tempo em dias e o eixo Y representa a precipitação acumulada (mm). . .	24
Figura 6 – Exemplo da previsão com dados desnormalizados no treinamento do LSTM com 256 neurônios e na base de dados do BR-DWGD. . .	25
Figura 7 – Exemplo da previsão com dados normalizados no treinamento do LSTM com 256 neurônios e na base de dados do BR-DWGD. . .	26
Figura 8 – Exemplo da previsão com dados normalizados no treinamento do BR-DWGD. O LSTM e BiLSTM com 64 neurônios. O eixo X representa o tempo em dias e o eixo Y representa a precipitação acumulada (mm).	26
Figura 9 – Exemplo da previsão com dados normalizados no treinamento do MERGE. O LSTM e BiLSTM com 64 neurônios. O eixo X representa o tempo em dias e o eixo Y representa a precipitação acumulada (mm).	27
Figura 10 – Exemplo da previsão com novos atributos do BR-DWGD. O LSTM e BiLSTM com 64 neurônios. O eixo X representa o tempo em dias e o eixo Y representa a precipitação acumulada (mm).	27

APÊNDICE B - Lista de tabelas

Tabela 1	–	Hiper-parâmetros dos modelos de aprendizado de máquina LSTM e BiLSTM	21
Tabela 2	–	Métricas dos modelos com dados desnormalizados do BR-DWGD	23
Tabela 3	–	Métricas de qualidade dos modelos com dados desnormalizados do MERGE.	24
Tabela 4	–	Métricas dos modelos com dados normalizados do BR-DWGD. . .	25
Tabela 5	–	Métricas de qualidade dos modelos com dados normalizados do MERGE.	26
Tabela 6	–	Métricas de qualidade dos modelos com novos atributos do BR-DWGD.	27
Tabela 7	–	Resultado de Tempo e Energia com dados desnormalizados do BRDWGD. Unidades de medida: tempo (min), pegada de carbono (kg) e energia (kWh).	28
Tabela 8	–	Resultado de Tempo e Energia com dados desnormalizados do MERGE. Unidades de medida: tempo (min), pegada de carbono (kg) e energia (kWh).	28
Tabela 9	–	Resultado de Tempo e Energia com dados normalizados do BRDWGD. Unidades de medida: tempo (min), pegada de carbono (kg) e energia (kWh).	29
Tabela 10	–	Resultado de Tempo e Energia com dados normalizados do MERGE. Unidades de medida: tempo (min), pegada de carbono (kg) e energia (kWh).	29
Tabela 11	–	Resultado de Tempo e Energia com novas <i>features</i> do BR-DWGD. Unidades de medida: tempo (min), pegada de carbono (kg) e energia (kWh).	29

Agradecimentos

Agradeço, em primeiro lugar, aos meus pais, Paulo Roberto e Silvana, pelo apoio imensurável ao longo da minha vida. Vocês são muito especiais para mim e cada oportunidade que tive foi graças a vocês, agradeço do fundo do meu coração. Aos meus irmãos, Paulo e Luísa, ao meu padrinho, a minha madrinha, Zé Mauro e Adriana e toda minha família, por sempre estarem ao meu lado me apoiando, dividindo tudo que há de bom nessa vida.

Aos meus amigos da Ilha do Governador, do Az, da faculdade e dos estágios, muito obrigado por vocês estarem na minha vida. Foram momentos de descontração, idas à praia, encontros em barzinhos e até inúmeras horas jogando no computador, que me ajudaram a aguentar dia após dia.

À minha namorada, Marina, agradeço por compartilhar a vida com você. Você me apoiou em todos os momentos. Foram horas de dedicação e estresse nas matérias e no estágio, mas tudo foi melhor com você. Estamos no formando juntos e seguiremos nossa trajetória juntos.

Ao meu orientador, professor Leandro Santiago, agradeço profundamente por todo apoio acadêmico nesse ano para o desenvolvimento desta pesquisa.

À Universidade Federal Fluminense e a todos os professores com quem tive contato ao longo desses anos, deixo meu agradecimento pela formação sólida e pelo ambiente de aprendizado proporcionado. Viva universidade pública!